Análise de Dados com Python – MYSQL[T2]

Situação de Aprendizagem (Projeto Avaliativo) - Módulo 2 - Semana 13

SUMÁRIO

1. CONTEXTUALIZAÇÃO
2. DESAFIO
3. RESULTADOS ESPERADOS (ENTREGA)
4. REQUISITOS DA APLICAÇÃO
    4.1. BASE DE DADOS OFICIAL E RECORTE TEMPORAL
    4.2. TRATAMENTO E LIMPEZA (PYTHON)
    4.3. MODELAGEM DIMENSIONAL E CARGA (MYSQL)
    4.4. PERGUNTAS DE NEGÓCIO DA CONTROLADORIA
    4.5. POWER BI E DESIGN SYSTEM
    4.6. POWER BI: AS 15 MEDIDAS E A HISTÓRIA DE CADA PERGUNTA
    4.7. PROVA REAL: COMO CONFERIR O SEU TRABALHO
5. ROTEIRO DA APLICAÇÃO
    5.1. FORMATO DO SISTEMA
    5.2. DOCUMENTAÇÃO NO README.MD
    5.3. PLANEJAMENTO EM SPRINTS (FERRAMENTA LIVRE)
    5.4. USO DO GITHUB
    5.5. GRAVAÇÃO DE VÍDEO (REVIEW DE SPRINT)
6. CRITÉRIOS DE AVALIAÇÃO
7. ANEXO: DICIONÁRIO DOS DADOS BRUTOS (data/raw/)
    7.1. COMPRAS.CSV — UMA LINHA POR CONTRATAÇÃO (O "EDITAL")
    7.2. ITENS.CSV — UMA LINHA POR ITEM LICITADO
    7.3. RESULTADOS.CSV — UMA LINHA POR FORNECEDOR CLASSIFICADO EM CADA ITEM
    7.4. ANTES DE COMEÇAR, DESCUBRA (E ANOTE NO SEU README)
    7.5. TABELA DE MODALIDADES (MODALIDADE_ID → NOME)
    7.6. TABELA UF → REGIÃO (PARA A PERGUNTA 5; O ARQUIVO NÃO TRAZ A REGIÃO)
8. ANEXO: NÚMEROS DE CONFERÊNCIA (PROVA REAL)

1. CONTEXTUALIZAÇÃO

Você foi contratado como **Analista de Dados** por uma consultoria de inteligência governamental que atende órgãos de controle e transparência pública. Recentemente, a Controladoria identificou gargalos operacionais severos nas compras e contratações públicas federais: indícios de **sobrepreço** em itens homologados, **concentração atípica** de contratos

em determinados grupos econômicos, **morosidade** excessiva entre a publicação de editais e o fechamento dos certames e **baixa adesão competitiva** em certas modalidades.

Para complicar o cenário, os sistemas legados de onde os dados são extraídos não possuem travas rígidas de validação na ponta. O resultado é um repositório bruto repleto de anomalias: identificadores corrompidos, campos monetários preenchidos em texto livre, inconsistências lógicas de cronograma e formatos de data despadronizados. A liderança governamental precisa de clareza para a tomada de decisão estratégica e auditoria contínua, mas hoje não confia nos relatórios gerados a partir desses dados brutos.

Sua missão é liderar o desenvolvimento de uma esteira analítica ponta a ponta (End-to-End), transformando esse mar de dados corrompidos em um ambiente analítico **confiável, auditável e executivo**.

A base oficial é o **Portal Nacional de Contratações Públicas (PNCP)** / Dados Abertos do Governo Federal (dados.gov.br), com recorte mínimo de 6 meses consecutivos (neste projeto, o ano de 2025 já extraído pelo professor, que você usa por inteiro), cruzando obrigatoriamente os dados de cabeçalho dos certames (órgãos, datas, modalidades) com os dados dos itens licitados (valores unitários estimados e homologados, quantidades e descrições).

Arquivos a serem utilizados: Projeto Final - Módulo 2 - Google Drive

2. DESAFIO

Ao construir a aplicação proposta, você colocará em prática os aprendizados em:

- Planejar e estruturar a solução em **Sprints**, justificando cada etapa técnica do pipeline;
- Auditar, sanitizar e tratar as falhas estruturais da base utilizando **Python** (pandas);
- Estruturar a camada analítica com **modelagem dimensional (Star Schema)** e integridade referencial no **MySQL**;
- Construir um produto visual no **Power BI** que responda às dores da Controladoria, aplicando princípios de design de dashboards (CRAP) e usabilidade avançada;
- Trabalhar com Git/GitHub, versionando o projeto com commits claros;
- Organizar o trabalho em **Sprints**, usando a ferramenta de gestão visual de sua escolha (Jira, Notion, GitHub Projects, Miro, planilha...), e **expor essa organização no vídeo**;
- Apresentar a defesa técnica em formato de **Review de Sprint** por vídeo.

3. RESULTADOS ESPERADOS (ENTREGA)

O código deverá ser inserido e versionado no **GitHub em modo público**, o vídeo deverá ser inserido no **Google Drive em modo leitor para qualquer pessoa com o link**, e o planejamento das Sprints pode ser feito na **ferramenta de sua escolha** (a organização será apresentada visualmente no vídeo). Os dois links (GitHub e vídeo) deverão ser disponibilizados na tarefa Módulo 2 - Projeto Avaliativo, presente na semana 13 do AVA até o dia **03/11/2026 às 22h.**

O repositório deverá ser público, para que a correção seja feita direto pelo link, sem convite. Antes de entregar, abra os dois links em uma janela anônima do navegador e confirme que abrem sem pedir login.

Não serão aceitos projetos submetidos após a data limite da atividade, e/ou alterados depois de entregues.

Importante:

- Será considerado como data final de entrega a última atualização no repositório do projeto no GitHub. Lembre-se de não modificar o código até receber sua nota.
- Não se esqueça de submeter os dois links (repositório e vídeo) no AVA. Os links não submetidos terão penalidade na nota.
- Entregue também o arquivo do Power BI (.pbix) dentro da pasta powerbi/ do repositório.
- **Respostas:** só serão aceitas como resposta as medidas mostradas no dashboard (Power BI) e as consultas escritas no arquivo sql/02_perguntas.sql. Número solto, sem a medida ou a consulta que o gera, não será aceito.

4. REQUISITOS DA APLICAÇÃO

Abaixo seguem os requisitos a serem desenvolvidos.

4.1. BASE DE DADOS OFICIAL E RECORTE TEMPORAL

- **Fonte obrigatória:** Portal Nacional de Contratações Públicas (PNCP) / Dados Abertos do Governo Federal (dados.gov.br). Conjunto: Contratações Públicas / Licitações e Itens Contratados. A extração do portal ou da API oficial (https://pncp.gov.br/api/consulta/) já foi feita pelo professor: você usa os arquivos da pasta data/raw e não precisa baixar nada.
- **Recorte temporal obrigatório:** a base fornecida em data/raw já cobre 12 meses consecutivos (de 02/01/2025 a 31/12/2025), acima do mínimo de 6 meses exigido. Use-a por inteira: não filtre meses nem baixe outros períodos.
- **Escopo mínimo de relacionamento:** cruzar os dados de cabeçalho dos certames (órgãos, datas, modalidades) com os dados de itens licitados (valores unitários estimados e homologados, quantidades e descrições).
- **Material de apoio:** o professor disponibiliza os arquivos brutos já extraídos do PNCP (pasta data/raw, ano de 2025), de modo que você não precise consumir a API, e uma **prova real** (anexo, seção 8) com números de referência para conferir a limpeza, as tabelas e o banco. **O kit traz roteiros com lacunas**: os scripts Python da pasta src/ têm trechos marcados com ____ para você completar, cada um com um comentário curto dizendo o que fazer. Os scripts SQL (criar as tabelas e responder às perguntas) você escreve, guiado pelas seções 4.3 e 4.4. Você se baseia nos trabalhos anteriores e no guia de referências.

4.2. TRATAMENTO E LIMPEZA (PYTHON)

O código Python deve auditar, tratar e documentar as armadilhas da base. No kit, as funções de limpeza estão em src/limpeza.py e as etapas das regras de negócio em src/montar_tabelas.py, com lacunas ____ para você completar (cada uma com um comentário dizendo o que fazer):

#	Desafio	O que tratar
1	Documentos e identificadores (CNPJ/CPF)	Inconsistências de máscaras, perda de zeros à esquerda causada por conversões e mistura de tipos de pessoa.
2	Padrões monetários e decimais	Valores em texto com R$, inversão de separadores de milhar e decimal, espaços invisíveis e valores negativos entre parênteses.
3	Coerência temporal e formatos de data	Múltiplas máscaras de data no mesmo campo e violações cronológicas (homologação, campo data_resultado, anterior à publicação do edital).
4	Campos “zumbis” e nulos disfarçados	Strings que representam nulos: "N/A", "NULL", "-", "0", "SEM INFORMAÇÃO", "NÃO SE APLICA". O "0" só é nulo em campos de texto; em quantidades e valores o 0 é um número.
5	Sanitização textual e encodings	Caracteres corrompidos (Latin-1/UTF-8) e padronização de nomenclatura de órgãos, fornecedores e itens.

Regras de negócio da Controladoria. Estas decisões já foram tomadas e você as implementa; é com elas que o seu resultado vai bater com a **prova real** (seção 4.7).

- **Grão da fato:** uma linha por **item de contratação** (numero_controle_pncp + numero_item).
- **Um vencedor por item.** Em Registro de Preços, um item tem vários classificados. Primeiro descarte os resultados com data_cancelamento preenchida; só depois, entre os que sobraram, fique só com o **1º colocado** (menor ordem_classificacao_srp; vazio conta como 1). A ordem importa: se o 1º colocado estiver cancelado, o 2º classificado assume o lugar dele. **Empate:** se mais de um resultado ficar com a mesma ordem (comum em Credenciamento, onde todos vêm com a ordem vazia), fique com o de **menor sequencial_resultado** (lido como número: 2 vem antes de 10).
- **Só entram na fato itens com resultado.** Itens sem resultado homologado ficam de fora, inclusive os que só têm resultados cancelados. São 852 itens (anexo 8) e eles não contam como rejeitados.
- **Itens rejeitados:** itens com dados impossíveis não entram na fato. Esta regra só é avaliada nos itens que sobraram da regra 3 (os que têm resultado): item sem resultado não é “rejeitado”, já foi descartado antes. Na ordem do código, a regra 5 (valores) vem antes desta: calcule quantidade e valores totais primeiro e só depois rejeite. Não precisa criar arquivo: não os carregue, conte quantos foram (a prova real confere esse total) e anote os motivos no README. Rejeite o item em que ocorrer qualquer um destes casos (use a quantidade e os valores já calculados pela regra 5): quantidade vazia ou ≤ 0; valor unitário estimado ausente ou ≤ 0; valor unitário homologado

ausente ou ≤ 0; orçamento sigiloso (sigiloso = True); valor total estimado < R$ 1; valor total homologado mais de 1.000× o estimado; ou qualquer valor total acima de R$ 1 trilhão (esse último estoura o tipo DECIMAL do banco: o banco é a sua segunda barreira). Se o item cair em vários casos, anote só o primeiro motivo; na conferência o que conta é o total.

- **Valores:** valor_total = valor_unitario × quantidade, usando a quantidade homologada (se vier vazia ou zero, use a quantidade do item) tanto no valor estimado quanto no homologado, para a comparação ser justa.
- **Economia só onde dá para comparar.** Um item é **comparável** quando **não** é Credenciamento (modalidade_id = 12; o estimado ali é um teto global) **e** a razão homologado ÷ estimado fica de **0,1 a 10 (inclusive)**. Itens não comparáveis **ficam na fato** (contam no volume), mas **não entram na economia**: economia = estimado − homologado só nos comparáveis; o percentual é **soma da economia ÷ soma do estimado comparável** (nunca média de percentuais). Consequência: em Credenciamento (modalidade_id = 12) nenhum item é comparável, então a economia % dessa modalidade fica **vazia** (é esperado, não é erro).
- **Cronologia:** homologação (data_resultado) **anterior** à publicação é impossível: o item fica **sem data de homologação e sem ciclo**, mas continua na fato. ciclo = homologação − publicação em dias. Compare só as datas (sem a hora): homologação no mesmo dia da publicação é válida, com ciclo de 0 dia.
- **Perfil do gasto** (pergunta 6): classifique cada item em **Bens**, **Serviços** ou **Obras e engenharia**. Use material_ou_servico (Material ou Serviço; a coluna categoria_item vem toda como "Não se aplica" e não ajuda); para separar Obras, escolha palavras-chave na descrição do item e no objeto_compra da contratação, juntos (a referência usa estas quatro: obra, construção, reforma, engenharia; com outras palavras o resultado muda um pouco) e documente as palavras que escolheu. Procure a palavra inteira, não um pedaço dela: use os limites de palavra \b da expressão regular (ex.: \bobra\b); sem eles, "cobrança" e "dobradiça" viram obra. O kit já traz essa expressão pronta em src/montar_tabelas.py. Se aparecer uma palavra de obra, o item é Obras e engenharia (ela tem prioridade, mesmo que o item seja Material ou Serviço); nos demais casos, Material vira Bens e Serviço vira Serviços. Se quiser ir além, separe serviços continuados de eventuais (opcional).
- **Modalidade:** use modalidade_id como chave (4 Concorrência - Eletrônica, 5 Concorrência - Presencial, 6 Pregão - Eletrônico, 7 Pregão - Presencial, 8 Dispensa, 9 Inexigibilidade, 12 Credenciamento) e padronize o nome a partir dela.
- **Órgão:** o mesmo órgão aparece com várias unidades (CNPJ diferentes) e com o nome escrito de jeitos diferentes. No ranking por órgão (pergunta 4) agrupe pelo **nome padronizado** e mostre só órgãos com **5 ou mais itens com ciclo**; para contar unidades compradoras, conte CNPJ distintos. O cnpj_orgao também vem sujo (máscara, zero perdido): limpe como o do fornecedor.
- **Região (pergunta 5):** o arquivo não traz a região. Monte você mesmo a partir da uf_sigla (a tabela UF → região está no anexo, seção 7).
- **Separadores numéricos:** nesta base, um ponto ou uma vírgula **sozinho** é sempre o **decimal** (0,754 e 746.815 valem 0,754 e 746,815, não 754 nem 746 mil). Só o separador repetido (1.234.567) é milhar; quando aparecem os dois símbolos, o último é o decimal.

Termos usados nas perguntas: volume é a soma do valor total homologado de todos os itens da fato (comparáveis ou não); deságio é o mesmo que economia %; fornecedor é o CNPJ/CPF já limpo (ni_fornecedor), então o mesmo nome com CNPJ diferente (filiais) conta como fornecedores diferentes.
Se você discordar de uma regra, não a mude: anote a discordância no README. A prova real foi calculada com estas regras.
Onde cada coisa é feita. Python: tratar os CSVs (src/limpeza.py), montar a fato e as dimensões (src/montar_tabelas.py) e carregar no banco (src/carregar.py). MySQL: criar as tabelas (o sql/01_criar_banco.sql é seu) e garantir chaves e restrições, e responder às 6 perguntas (o sql/02_perguntas.sql é seu). Power BI: relacionar as tabelas, criar o Calendário e as medidas e montar as páginas. As duas tabelas abaixo dizem, para cada arquivo e para cada regra, o que tratar e onde.

Arquivo	O que tratar em cada coluna	Destino
compras.csv uma linha por contratação (2.042 linhas)	**cnpj_orgao:** limpar máscara e zero perdido (desafio 1) **razao_social_orgao, nome_unidade:** padronizar texto e encoding (desafio 5; regra 10) **uf_sigla, uf_nome:** padronizar e criar a região (regra 11) **modalidade_id, modalidade_nome:** usar o id e padronizar o nome (regra 9) **data_publicacao:** converter para data (desafio 3) **objeto_compra:** corrigir encoding; ajuda a classificar o perfil do gasto (regra 8)	**Vai para:** dim_orgao, dim_localidade, dim_modalidade e as datas da fato
itens.csv uma linha por item (7.077 linhas)	**quantidade, valor_unitario_estimado, valor_total_estimado:** converter dinheiro e números (desafio 2; regras 5 e 12) **descricao:** corrigir encoding e padronizar (desafio 5); entra no perfil do gasto (regra 8) **material_ou_servico:** base do perfil do gasto (regra 8) **sigiloso, tem_resultado:** decidem quais itens entram na fato (regras 3 e 4) **qualquer coluna:** nulos disfarçados: N/A, -, 0 em texto (desafio 4)	**Vai para:** colunas da fato: descricao_item, perfil_gasto, quantidade e valores estimados
resultados.csv uma linha por fornecedor classificado (15.896 linhas)	**ni_fornecedor:** limpar CNPJ/CPF (desafio 1) **nome_fornecedor, tipo_pessoa, porte:** padronizar texto (desafio 5) **quantidade_homologada, valor_unitario_homologado, valor_total_homologado:** converter dinheiro e números (desafio 2; regras 5 e 12) **data_resultado:** converter para data e conferir com a publicação (desafio 3; regra 7) **ordem_classificacao_srp, sequencial_resultado, data_cancelamento:** escolher o vencedor de cada item (regra 2)	**Vai para:** dim_fornecedor e colunas da fato: valores homologados e data_homologacao

Em qual arquivo e em qual ferramenta cada regra de negócio é aplicada:

Regra	Onde se aplica	Onde fazer
1. Grão da fato	itens + resultados → fato_item_contratado	Python monta; o banco garante com UNIQUE (numero_controle_pncp + numero_item)
2. Um vencedor por item	resultados → fato	Python
3. Só itens com resultado	itens + resultados → fato	Python
4. Itens rejeitados	itens que têm resultado (com os valores já calculados) → ficam fora da fato	Python (não carrega); o banco é a 2ª barreira (CHECK e DECIMAL)
5. Valores	itens + resultados → valor_total_* da fato	Python
6. Comparável e economia	fato: comparavel e economia_valor	Python grava as colunas; Power BI usa nas medidas
7. Cronologia	compras + resultados → fato: data_homologacao e dias_ciclo	Python anula a data; Power BI: a média ignora os vazios
8. Perfil do gasto	itens (+ objeto_compra) → fato: perfil_gasto	Python
9. Modalidade	compras → dim_modalidade	Python padroniza o nome; o banco guarda
10. Órgão	compras → dim_orgao	Python limpa CNPJ e nome; Power BI agrupa por nome e conta CNPJ distintos
11. Região	compras.uf_sigla → dim_localidade.regiao	Python
12. Separadores numéricos	valores e quantidades de itens e resultados	Python, na leitura, antes de qualquer conta

4.3. MODELAGEM DIMENSIONAL E CARGA (MYSQL)

- **Star Schema:** 1 tabela Fato e 4 Dimensões no banco (órgão, fornecedor, modalidade e localidade); o tempo é o Calendário criado em DAX no Power BI. A fato guarda os números (o que se mede) e a descrição do item; cada dimensão guarda descrições (quem, como, onde) e se liga à fato por uma chave substituta. Não será aceito "tabelão" único desnormalizado.
- **Integridade:** chaves substitutas (surrogate keys), constraints e relacionamentos lógicos consistentes.
- **Pipeline automatizado:** o script Python realiza a ingestão estruturada dos dados tratados diretamente no banco de dados, em lote e com tratamento de integridade.

- **Quem é quem:** no banco são 5 tabelas (1 fato + 4 dimensões); no Power BI entra o Calendário em DAX, a dimensão de tempo. Use estes nomes de tabelas e colunas (facilita conferir com a prova real e corrigir). Colunas extras são permitidas; as listadas são obrigatórias.

Tabela	Papel e linhas esperadas	Campos obrigatórios
fato_item_contratado	**FATO: o que foi comprado.** Uma linha por item de contratação, com o vencedor (regra 1). Esperado: 6.126 linhas.	**Chave:** sk_fato (PK); numero_controle_pncp + numero_item (juntos são únicos) **Ligações (FK):** sk_orgao, sk_fornecedor, sk_modalidade, sk_localidade **Datas:** data_publicacao; data_homologacao (vazia quando a regra 7 a anula) **Item:** descricao_item; perfil_gasto (Bens, Serviços ou Obras e engenharia) **Números:** quantidade; valor_unitario_estimado; valor_unitario_homologado; valor_total_estimado; valor_total_homologado **Calculados por você:** comparavel (1 ou 0, regra 6); economia_valor (estimado − homologado, só nos comparáveis); dias_ciclo (vazio quando não há ciclo)
dim_orgao	**DIMENSÃO: quem comprou.** Uma linha por CNPJ de órgão (unidade compradora). Esperado: 363 linhas.	sk_orgao (PK); cnpj_orgao (limpo, único); nome_orgao (nome padronizado, regra 10); poder (nome por extenso, a partir de poder_id: E = Executivo, L = Legislativo, J = Judiciário, N = Não informado)
dim_fornecedor	**DIMENSÃO: quem vendeu.** Uma linha por CNPJ/CPF de fornecedor. Esperado: cerca de 2.652 linhas (varia um pouco com o tratamento do documento ausente).	sk_fornecedor (PK); ni_fornecedor (limpo, único); nome_fornecedor; tipo_pessoa; porte
dim_modalidade	**DIMENSÃO: como comprou.** Uma linha por modalidade. Esperado: 7 linhas.	sk_modalidade (PK); modalidade_id (único); nome_modalidade (nomes da tabela de modalidades do anexo, seção 7)
dim_localidade	**DIMENSÃO: onde.** Uma linha por UF. Esperado: 27 linhas.	sk_localidade (PK); uf_sigla (único); uf_nome; regiao (montada pela regra 11)
Calendario (só no Power BI)	**DIMENSÃO: quando.** Criada em DAX; não é tabela do banco (seção 4.5).	Data (única), Ano, Mês (número e nome) e Ano-Mês (detalhes na seção 4.6). Relacionada a data_publicacao e a data_homologacao da fato.

- **Chaves:** toda tabela tem chave primária substituta (sk_...); as dimensões guardam também a chave natural (cnpj_orgao, ni_fornecedor, modalidade_id, uf_sigla) como UNIQUE.

- **Sem FK solta:** toda FK da fato aponta para uma linha que existe. Se faltar o dado, crie a linha "Não informado" (sk = -1; não use 0: no MySQL, inserir 0 numa coluna AUTO_INCREMENT gera o próximo número em vez de gravar o 0) na dimensão (ela não conta nas linhas esperadas da tabela acima). A linha −1 só é necessária se sobrar FK sem destino; a chave natural dela deve ser um valor que não existe nas outras linhas (a coluna é única e não aceita vazio).
- **Vazios:** data_homologacao e dias_ciclo ficam vazios (NULL) quando a regra 7 anula a homologação; economia_valor fica vazia nos itens não comparáveis.
- **CHECK:** a fato não aceita quantidade ≤ 0 nem valores negativos (o banco é a sua segunda barreira).
- **Script de criação:** salve como sql/01_criar_banco.sql (a carga o executa). Tipos sugeridos: texto = VARCHAR (descrição do item = TEXT), dinheiro = DECIMAL(18,2), preços unitários e quantidades = DECIMAL(18,4), datas = DATE, 1 ou 0 = TINYINT; chaves sk = INT com sinal (sem UNSIGNED: senão o −1 da linha "Não informado" é recusado). No MySQL, comece o script com CREATE DATABASE IF NOT EXISTS pncp_controladoria e USE pncp_controladoria.

4.4. PERGUNTAS DE NEGÓCIO DA CONTROLADORIA

O modelo de dados e o dashboard final devem responder objetivamente às 6 perguntas estratégicas:

#	Tema	Pergunta
1	Economia global do Poder Público	Qual é o percentual e o valor financeiro nominal economizado pelo governo (diferença entre valor estimado e valor homologado)?
2	Concentração e risco de fornecedores	Quem são os maiores fornecedores em volume financeiro e qual percentual do orçamento público está concentrado neles?
3	Eficácia por modalidade	Quais modalidades licitatórias trazem maior deságio/economia e quais concentram o maior volume de recursos?
4	Tempo do ciclo de compras	Qual a duração média (em dias) entre o lançamento do edital e a sua homologação final, segmentada por órgão?
5	Distribuição regional	Quais estados e regiões concentram as maiores despesas e quais apresentam os melhores indicadores de desconto?
6	Perfil dos gastos	Como os recursos se distribuem entre bens, serviços e obras e engenharia?

Dicas para o SQL: (1) percentual = SOMA ÷ SOMA, nunca média de percentuais; (2) a economia só conta os itens comparáveis (comparavel = 1): estimado comparável = SUM(CASE WHEN comparavel = 1 THEN valor_total_estimado ELSE 0 END); (3) quando o denominador pode ser zero (Credenciamento não tem item comparável), use NULLIF(denominador, 0); (4) pergunta 2: os 10 maiores com ORDER BY … DESC e LIMIT 10, e o percentual do total com

uma subconsulta no denominador; (5) pergunta 4: agrupe pelo NOME do órgão, conte só itens com ciclo (COUNT(dias_ciclo)) e use HAVING para ficar com 5 ou mais; (6) perfil do gasto é coluna da própria fato (não precisa de JOIN). Salve as consultas em sql/02_perguntas.sql e rode no Workbench, comparando com a prova real.

Atenção: Só serão aceitas como resposta as medidas mostradas no dashboard (Power BI) e as consultas escritas no arquivo sql/02_perguntas.sql. Número solto, sem a medida ou a consulta que o gera, não será aceito.

4.5. POWER BI E DESIGN SYSTEM

- **Tabela Calendário dinâmica em DAX** (CALENDAR/CALENDARAUTO), com colunas temporais essenciais e ordenação correta das colunas textuais (ex.: Mês/Ano ordenado por número). O uso da hierarquia automática de data do Power BI é **estritamente proibido**.
- **Boas práticas em DAX: no mínimo 15 medidas explícitas**, em tabela dedicada, com VAR/RETURN e funções analíticas e de contexto (CALCULATE, DIVIDE, iteradoras). O kit traz a **lista das 15 medidas obrigatórias** (nome e o que calculam); a fórmula DAX é do aluno. As medidas devem **contar a história de cada uma das 6 perguntas** (pergunta → números → conclusão).
- **Navegação executiva (UX):** menu retrátil/interativo com botões e indicadores (bookmarks).
- **Dica de ferramenta personalizada (Tooltip):** página de tooltip para detalhamento contextual dinâmico ao passar o mouse sobre elementos-chave.
- **Princípios de design (CRAP):** Contraste, Repetição, Alinhamento e Proximidade; hierarquia visual (leitura em Z ou F) e uso das cores com propósito (destacar o que importa, sem enfeite).

4.6. POWER BI: AS 15 MEDIDAS E A HISTÓRIA DE CADA PERGUNTA

Esta seção diz **o que medir** (nome e o que cada medida calcula) e **como contar a história** de cada pergunta. A **fórmula DAX é sua**: pesquise na documentação do Power BI e nas aulas. Salve o arquivo .pbix na pasta powerbi/.

Antes de começar

- Importe do **seu banco** as tabelas do modelo estrela (fato + dimensões) com o conector de MySQL. O Power BI precisa do driver MySQL Connector/NET 8.x instalado no Windows (sem ele aparece o erro de provedor MySql.Data.MySqlClient não encontrado).
- **Coluna extra ao importar:** o Power BI pode mostrar, no fim de cada tabela, uma coluna com o nome de outra tabela e duas setinhas. Você não vai usá-la: ignore-a ou desmarque “Incluir colunas de relacionamento” ao importar. Os relacionamentos você cria na visão de modelo.
- Crie os relacionamentos 1:N das dimensões para a fato e esconda as colunas técnicas (chaves) do modo de exibição de relatório.

- **Desligue a hierarquia automática de data** (Arquivo → Opções → Arquivo atual → Carregamento de dados → Hora/data automática).
- **Calendário em DAX:** limites vindos dos dados (não digitados); nome do mês ordenado pelo número do mês; ano-mês ordenado por um número AAAAMM; marque como tabela de datas. Relacione o Calendário às duas datas da fato (data_publicacao e data_homologacao); só uma relação fica ativa (pesquise USERELATIONSHIP).

As 15 medidas obrigatórias. Crie uma tabela só para as medidas (nada de soma implícita arrastando coluna). Use VAR/RETURN, CALCULATE, DIVIDE e pelo menos uma iteradora (SUMX, AVERAGEX...). **Percentual = DIVIDE(soma, soma)**, nunca média de percentuais. Os nomes podem ser os seus; o importante é cada medida calcular o que está descrito. Organize por pasta de exibição (uma por pergunta).

#	Pergunta	Medida (nome sugerido)	O que calcula
1	P1 Economia	Valor Estimado Comparável	Soma do valor estimado só dos itens comparáveis. *Dica: CALCULATE com SUM de valor_total_estimado e a condição comparavel = 1.*
2	P1 Economia	Volume Homologado	Soma do valor total homologado de todos os itens. *Dica: SUM.*
3	P1 Economia	Economia (R$)	Estimado comparável − homologado dos itens comparáveis *Dica: reaproveite a medida 1 e a medida 2 filtrada por comparavel = 1 (CALCULATE com uma condição); guarde cada uma em uma VAR e devolva a diferença no RETURN.*
4	P1 Economia	Economia %	Economia (R$) ÷ Valor Estimado Comparável *Dica: DIVIDE, usando as medidas 3 e 1.*
5	P1 Economia	% de Itens Comparáveis	Itens comparáveis ÷ total de itens (mostra quanto da base entra no cálculo da economia) *Dica: COUNTROWS e CALCULATE com condição, dentro de um DIVIDE.*
6	P2 Fornecedores	Participação do Fornecedor %	Volume do fornecedor ÷ volume total (o total ignora o filtro de fornecedor) *Dica: DIVIDE e CALCULATE com ALL na dimensão de fornecedor.*
7	P2 Fornecedores	Ranking do Fornecedor	Posição do fornecedor por volume (1º, 2º, 3º...). *Dica: RANKX com ALL*

8	P2 Fornecedores	Concentração Top 10 %	Volume dos 10 maiores fornecedores ÷ volume total *Dica: TOPN para pegar os 10 maiores fornecedores e KEEPFILTERS dentro do CALCULATE para somar só o volume deles; divida pelo volume total, obtido com ALL.*
9	P3 Modalidades	Participação no Volume %	Volume da linha atual (modalidade, UF, perfil...) ÷ volume total *Dica: Mesmo modelo da medida 6, tirando o filtro da dimensão da linha (ALL ou ALLSELECTED).*
10	P3 Modalidades	Deságio vs Média Geral (p.p.)	Economia % da linha atual − Economia % geral (sem nenhum filtro), em pontos percentuais. *Dica: CALCULATE com REMOVEFILTERS (ou ALL) para obter a Economia % geral, sem filtros; depois subtraia e multiplique por 100. Formate a medida como número com 1 casa decimal (ex.: 2,5), nunca como %: formatada como %, a diferença de 5 p.p. apareceria como 500%.*
11	P4 Ciclo	Ciclo Médio (dias)	Média dos dias entre publicação e homologação, ignorando itens sem ciclo *Dica: AVERAGE: itens sem ciclo ficam em branco e a média já os ignora.*
12	P4 Ciclo	Ciclo Máximo (dias)	Maior ciclo observado *Dica: MAX.*
13	P4 Ciclo	Itens sem Ciclo	Itens cuja homologação ficou sem data (anterior à publicação ou data inválida): total de itens − itens com ciclo *Dica: COUNTROWS menos COUNT da coluna de ciclo (COUNT ignora os vazios); ou CALCULATE com FILTER, pesquisando ISBLANK.*
14	P5 Regional	Qtd Unidades Compradoras	Número de CNPJ de órgão distintos (cada CNPJ é uma unidade compradora; o mesmo órgão pode ter várias) *Dica: DISTINCTCOUNT, sobre o CNPJ de órgão limpo (na dimensão, cnpj_orgao;*

			na fato, a chave sk_orgao dá o mesmo número).
15	P6 Perfil	Ticket Médio por Item (R$)	Volume homologado ÷ quantidade de itens *Dica: DIVIDE, entre o volume homologado e COUNTROWS.*

Extras opcionais (enriquecem a história): Itens com Sobrepreço · Variação Mensal % (volume contra o mês anterior) · Volume Acumulado no Ano · Título Dinâmico do Tooltip.
Uma história por pergunta. Cada página segue a mesma estrutura: a pergunta (título) → os números (medidas e visuais) → a conclusão (uma frase sua, numa caixa de texto, dizendo o que os números significam para a Controladoria). Os números do dashboard devem ser os mesmos do seu SQL.

Página	A história que ela conta	Medidas (n° da tabela)
1 Economia	Quanto o governo economizou?	1, 2, 3, 4, 5
2 Fornecedores	Quem concentra o orçamento? É um risco?	2, 6, 7, 8
3 Modalidades	Qual modalidade economiza mais e qual movimenta mais dinheiro?	2, 4, 5, 9, 10
4 Ciclo	Onde as compras demoram mais?	11, 12, 13
5 Regional	Onde se gasta mais e onde se consegue mais desconto?	2, 4, 9, 14
6 Perfil	Em que o dinheiro público é gasto: bens, serviços ou obras?	2, 4, 9, 15

No vídeo: abra e feche o menu, passe o mouse no tooltip, mostre o calendário e a ordenação do mês, mostre a tabela de medidas (explique 2 ou 3 delas, linha a linha) e **conte a história das 6 perguntas** com os números da tela e a sua conclusão para cada uma.

4.7. PROVA REAL: COMO CONFERIR O SEU TRABALHO

O anexo (seção 8) traz **números**, não código. O professor rodou o pipeline completo com as regras acima e anotou o que deve aparecer. Use para saber se você está no caminho; **não copie os números** para o seu trabalho, você precisa chegar a eles com o seu código e explicar como.

- Anexo 8, totais: o que a base limpa e o banco precisam ter (linhas dos arquivos, itens na fato, itens rejeitados, somas, economia, ciclo).

Como interpretar diferenças

O que aconteceu	O que provavelmente é
Faltam algumas dezenas de linhas na fato	Rejeição mais rígida/frouxa do que a regra 4
Faltam cerca de 60 itens na fato (ex.: 6.065 em vez de 6.126)	Você escolheu o 1º colocado antes de descartar os cancelados: o item perde o resultado em vez de ficar com o 2º classificado (regra 2)
A economia % está muito diferente (ex.: 75% em vez de 14%)	Você misturou os itens não comparáveis (regra 6)
Soma do homologado ≈ igual, mas nº de itens diferente	Itens sem resultado, cancelados ou duplicados por SRP
Muitos fornecedores a mais	CNPJ com máscara/sem zero tratado como fornecedor diferente
Ciclo médio muito diferente	Datas de homologação invertidas não foram anuladas (regra 7)
Órgãos repetidos no ranking com o mesmo nome	O mesmo órgão tem várias unidades (CNPJ). No ranking de ciclo agrupe pelo nome padronizado e mostre só órgãos com 5 ou mais itens com ciclo
Perfil de gasto com percentuais um pouco diferentes	Você usou palavras diferentes das 4 da referência ou esqueceu o limite de palavra (\b): se escolheu outras palavras é esperado, só documente (a referência usa 3 classes: bens, serviços e obras)
O volume homologado total é bem maior que R$ 8 bi (ex.: R$ 31 bi)	Você leu 0,754 ou 746.815 como milhar: ponto ou vírgula sozinho é decimal (regra de separadores)
Poucas linhas a mais ou a menos na fato ou no volume de fornecedores	Empate no 1º colocado resolvido de outro jeito: vale o menor sequencial_resultado

Pequenas diferenças são normais quando a sua definição é diferente e justificada. Diferenças grandes e sem explicação indicam erro: investigue antes de seguir.

5. ROTEIRO DA APLICAÇÃO

Abaixo segue um detalhamento de como a aplicação deve se comportar (arquitetura, repositório, planejamento e defesa).

5.1. FORMATO DO SISTEMA

Esteira em camadas, executável de ponta a ponta:
PNCP (API/arquivos brutos) → Python (auditoria + limpeza) → MySQL (Star Schema) → Power BI (dashboard executivo)
A estrutura de diretórios e a segregação de arquivos serão avaliadas. **Não serão tolerados arquivos jogados na raiz do projeto: é obrigatório organizar todos os arquivos em pastas.**

Roteiros do kit, na ordem: (1) src/limpeza.py (rode python -m src.limpeza: mostra ✓ ou ✗ em cada exemplo); (2) src/montar_tabelas.py; (3) o seu sql/01_criar_banco.sql e o src/carregar.py (rode python -m src.carregar); (4) o seu sql/02_perguntas.sql (rode as consultas no Workbench). Os scripts SQL, o dashboard do Power BI e o README do projeto são inteiramente seus.

5.2. DOCUMENTAÇÃO NO README.MD

Crie um arquivo README.md no repositório, **completo, profissional e autoral**, para documentar a sua solução. Ele deve conter:

- O contexto do problema e o nome do seu projeto;
- As decisões técnicas adotadas e por quê;
- O **dicionário das inconsistências** tratadas;
- O **diagrama da modelagem dimensional**;
- As técnicas e tecnologias utilizadas;
- As instruções de execução para que qualquer outro analista reproduza o pipeline do zero;
- A **figura das Sprints** (imagem que explique o planejamento: quadro, cronograma ou linha do tempo), importada no README;
- Melhorias futuras e o link do vídeo.

5.3. PLANEJAMENTO EM SPRINTS (FERRAMENTA LIVRE)

A ferramenta de planejamento é livre: Jira, Notion, Azure DevOps, GitHub Projects, Miro, planilha ou até um desenho. Divida o projeto em Sprints, com objetivo, tarefas, prazos e status de cada uma.

Não é preciso entregar link da ferramenta. Você vai **expor a organização no vídeo, mostrando visualmente as Sprints** (quadro, cronograma ou linha do tempo na tela), explicando como dividiu o trabalho, o que foi entregue em cada Sprint e o que mudou ao longo do caminho.

Figura obrigatória no repositório: salve uma imagem que explique as Sprints (print do quadro, cronograma ou linha do tempo) em **docs/img/sprints.png** e **importe-a no README.md** com ![Sprints do projeto](docs/img/sprints.png). A figura deve mostrar, no mínimo: o nome e o objetivo de cada Sprint, o período, as tarefas e o status de cada uma.

Sugestão de Sprints. Cada Sprint tem um objetivo e termina com algo conferível na prova real.

Sprint	Objetivo	Como saber que acabou
0	Repositório, planejamento, entender os dados	Você descreve cada coluna e vê as sujeiras nos CSVs

1	Auditar (contar os problemas)	Você anotou no README cada problema dos dados e quantos registros ele afeta
2	Limpar: completar src/limpeza.py	O autoteste (python -m src.limpeza) mostra ✓ em todos os exemplos
3	Montar as tabelas (dimensões e fato) com as regras da seção 4	Linhas e somas batem com o anexo 8
4	Banco: escrever o SQL de criação e completar a carga	Contagens no banco = contagens dos arquivos; zero FK solta
5	Perguntas em SQL	As respostas fazem sentido e são as mesmas no SQL e no dashboard
6	Power BI (≥ 15 medidas e uma história por pergunta)	As mesmas respostas aparecem no dashboard
7	README, figura das Sprints, vídeo	Alguém reproduz seu projeto só lendo o README

5.4. USO DO GITHUB

Utilize um repositório GitHub para controle de versionamento. Siga as diretrizes:

- Commits com descrição sucinta e direta e, de preferência, com poucos arquivos alterados por commit.
- Prefira mensagens no imperativo, como “implementa X” ou “corrige Y”, em vez de “X foi implementado”.
- Faça commits frequentes ao longo do projeto, para que o histórico mostre a evolução do trabalho.
- O código final do projeto deve estar na branch main do repositório.
- Deixe o repositório público (em Settings, no fim da página, em Danger Zone, Change visibility): a correção é feita abrindo o link do repositório, sem convite.

5.5. GRAVAÇÃO DE VÍDEO (REVIEW DE SPRINT)

Grave um vídeo de **no máximo 7 minutos**, hospedado no Google Drive com permissão pública de leitor, simulando uma apresentação técnica executiva:

- **Apresentação pessoal:** câmera aberta (rosto visível), boa iluminação e áudio nítido;
- **Defesa do pipeline Python:** abra o código e demonstre como as inconsistências e anomalias foram identificadas e higienizadas;
- **Defesa da arquitetura MySQL:** mostre a estrutura das tabelas e explique as decisões do Star Schema;
- **Demonstração do dashboard:** navegabilidade, menu com botões/bookmarks, tooltip customizado, calendário em DAX e como as visualizações respondem às perguntas de negócio;

- **Planejamento e lições aprendidas: mostre visualmente as Sprints** (na ferramenta que você usou), explicando a divisão do cronograma e o que foi entregue em cada uma, e aponte oportunidades de melhoria futuras.

Grave na horizontal (formato 16:9, como a tela do computador): na vertical, o código e as medidas DAX ficam ilegíveis na correção. Uma dica interessante é inserir o vídeo no README.md do repositório.

6. CRITÉRIOS DE AVALIAÇÃO

A tabela abaixo apresenta os critérios avaliados durante a correção do projeto. A nota vai de 0 (zero) a 10 (dez) e tem peso de xx% sobre a avaliação do módulo.
Atenção: cópias prontas da internet ou códigos gerados por inteligência artificial sem capacidade de explicação e defesa técnica no vídeo receberão **pontuação zero**. Você está livre para utilizar outras soluções como base, mas não é permitida a cópia.

Bloco 1 – Apresentação Técnica e Defesa do Projeto (Vídeo) — 3,50 pontos

Nº	Critério de Avaliação	0,0	0,25	0,50	0,75
01	**Defesa da sanitização de dados em Python**	Não apresentou o código no vídeo ou não explicou as decisões de limpeza de dados.	Apenas passou pelo código superficialmente, sem demonstrar a lógica dos filtros, nulos disfarçados ou conversão de tipos de moedas/datas.	Demonstrou a maioria das regras de limpeza (CNPJ/CPF, datas e moedas), mas deixou lacunas conceituais sobre o tratamento de nulos ocultos ou o critério de descarte/rejeição.	O estudante explicou o racional técnico adotado para o tratamento de dados, justificando a lógica dos filtros aplicados, a identificação e tratamento de nulos disfarçados, a conversão de tipos e as etapas de higienização em um cenário contextualizado do ecossistema de dados.
02	**Demonstração do produto no Power BI**	Não apresentou o dashboard ou mostrou apenas gráficos estáticos sem interação.	Demonstrou navegação elementar; não usou ou não funcionaram os menus/bookmarks/tooltips, ou respondeu	Navegação funcional com menu/tooltips, porém com pequenas falhas de fluidez ou deixando de cobrir/explicar	O painel/dashboard interativo apresenta estrutura de navegação intuitiva por meio

			superficialmente a menos de 4 perguntas de negócio.	com clareza 1 a 2 das 6 perguntas de negócio.	de menus funcionais e tooltips contextuais, integrando uma tabela de dimensão de calendário construída via DAX, permitindo responder com precisão e clareza analítica às 6 perguntas de negócio formuladas para o problema.
N°	Critério de Avaliação	0,0	0,35	0,70	1,00
03	**Justificativa da modelagem e ingestão no MYSQL**	Não explicou o banco de dados nem comprovou a ingestão das tabelas.	Mostrou o banco, mas com modelagem desnormalizada ("tabelão"), sem explicar as dimensões/fato ou com erros graves de chaves e integridade.	Explicou o Star Schema (1 fato e dimensões) e demonstrou a carga, mas com justificativas superficiais quanto a restrições/constraints, surrogate keys ou tratamento de integridade referencial.	A apresentação justifica a escolha da modelagem em Star Schema frente às regras de negócio, comprova a garantia da integridade referencial entre as tabelas fato e dimensão, e disponibiliza o script de carga estruturado e testado sem falhas de execução.
04	**Comunicação técnica e rastreabilidade**	Apresentação confusa, sem câmera aberta, ultrapassando expressivamente o tempo limite ou sem conexão com o projeto.	Vídeo com problemas de áudio/vídeo, sem mostrar o planejamento visual das Sprints ou sem articular as entregas com os commits do repositório.	Boa postura e oratória clara; mostrou o planejamento em Sprints, mas não articulou bem a evolução dos commits do GitHub ou deixou de apresentar a	A apresentação do projeto foi conduzida com oratória clara e postura profissional, utilizando recursos visuais para evidenciar a

				visão crítica de melhorias futuras.	evolução das Sprints, articulando o histórico de commits no repositório com as etapas desenvolvidas e propondo uma análise crítica fundamentada sobre potenciais melhorias no produto.

Bloco 2 – Gestão, Repositório e Arquitetura de Pastas — 1,50 pontos

Nº	Critério de Avaliação	0,0	0,15	0,30	0,40
05	**Arquitetura e organização de pastas**	Arquivos soltos na raiz do repositório, sem segregação de pastas.	Criou pastas, mas com arquivos misturados (ex.: bases de dados e scripts na mesma pasta ou arquivos temporários/lixo no repositório).	Segregação adequada da maioria dos arquivos (src/, sql/, powerbi/, docs/), mas com pequenas desorganizações ou ausência de uma pasta padronizada.	O projeto apresenta arquitetura de diretórios organizada de forma lógica e modular, segregando claramente código-fonte, scripts SQL, bases de dados, documentações e relatórios em pastas próprias, facilitando a manutenção e a rastreabilidade da aplicação.
06	**Versionamento no GitHub**	Repositório privado, sem commits ou entrega realizada em um único commit monolítico ("Initial commit").	Poucos commits concentrados no final do prazo, ou mensagens genéricas ("fix", "ajustes", "update") sem descrição do que foi alterado.	Commits frequentes ao longo do desenvolvimento, mas com granularidade irregular (muitos arquivos	O estudante aplicou boas práticas de controle de versão (Git), registrando commits frequentes e

				alterados por commit) ou mensagens sem padronização/imperativo.	granulares, acompanhados de mensagens claras e objetivas que explicam o propósito técnico de cada alteração no código.
07	**Documentação do projeto**	README padrão vazio ou ausente.	README incompleto, apenas listando links, sem instruções claras de reprodução ou sem explicar as regras de negócio tratadas.	README contextualizado com guia de execução e diagrama relacional, mas faltando a documentação detalhada das anomalias tratadas ou a imagem embutida das Sprints.	A documentação do projeto (README.md) contextualiza o problema de negócio e a solução desenvolvida, contendo o diagrama relacional do banco de dados, o registro visual do acompanhamento das Sprints e um guia de reprodução (passo a passo de instalação e execução) lógico e funcional.
Nº	Critério de Avaliação	0,0	0,10	0,20	0,30
08	**Planejamento das entregas**	Não apresentou planejamento em Sprints no vídeo nem no repositório.	Planejamento superficial (apenas uma lista de tarefas genérica sem status, prazos ou objetivos de Sprint definidos).	Planejamento em Sprints estruturado na ferramenta escolhida, mas a imagem não foi incluída em docs/img/ ou faltou detalhamento de tarefas/andamento no README.	Figura das Sprints em docs/img e no README, e Sprints expostas visualmente no vídeo (qualquer ferramenta), com objetivos, tarefas e andamento.

Bloco 3 – Tratamento, Limpeza e Banco de Dados (Python & MySQL) — 2,50 pontos

Nº	Critério de Avaliação	0,0	0,35	0,70	1,00
09	**Higienização de dados em Python**	Scripts de tratamento ausentes, não funcionais ou que não tratam as inconsistências da base.	Trata apenas problemas básicos de strings ou conversão direta com erros em separadores decimais (ex.: volume homologado explodindo em bilhões) ou nulos disfarçados não higienizados.	Pipeline trata a maioria dos desafios (CNPJ, moedas, datas, encodings e descarte de SRP cancelados), mas com pequenas discrepâncias na regra de rejeição ou na marcação de comparabilidade frente à prova real.	O pipeline/script de tratamento de dados apresenta a higienização completa da base, garantindo a padronização de identificadores, a conversão adequada de valores monetários e datas, o tratamento de strings e a eliminação ou substituição de nulos ocultos
Nº	Critério de Avaliação	0,0	0,25	0,50	0,75
10	**Modelagem dimensional Star Schema no MySQL**	Não criou as tabelas no MySQL ou estruturou como uma tabela única desnormalizada.	Criou tabelas separadas, mas sem chaves substitutas (SK), sem integridade referencial (FKs) ou com tipos inadequados (ex.: float em vez de decimal para valores monetários).	Star Schema implementado com Fato e as 4 Dimensões, com PKs e FKs, mas sem restrições complementares (CHECK, UNIQUE para chaves naturais) ou registros de exceção ("Não informado" / SK = -1).	O modelo multidimensional de dados apresenta a separação clara entre tabelas Fato e Dimensões, garantindo a consistência do modelo conceitual/lógico por meio do mapeamento correto de chaves primárias (PK) e chaves estrangeiras (FK) para suporte às análises.

11	**Pipeline de carga automatizada e integridade**	Sem script de carga automatizado (importação manual via assistente gráfico ou script com erro impeditivo).	Script em Python apenas executa comandos simples linha a linha, sem tratamento de erros, sem ingestão em lote (batch) e sem validação prévia de integridade.	Carga automatizada funcional em lote, mas sem tratamento claro de exceções/rollback ou com dependência de intervenção manual para rodar o DDL.	O script em Python realiza a ingestão em lote (batch processing) de dados de forma automatizada, aplicando validações de integridade, tratamento de exceções e controle de falhas durante o carregamento no repositório de destino.

Bloco 4 – Visualização, DAX e Princípios de Design (Power BI) — 2,50 pontos

Nº	Critério de Avaliação	0,0	0,15	0,35	0,50
12	**Tabela Calendário dinâmica em DAX**	Não criou tabela Calendário ou utilizou a hierarquia automática padrão de datas do Power BI.	Criou tabela de calendário com limites fixos (digitados estaticamente) e sem ordenação lógica configurada nas colunas de texto (ex.: mês por ordem alfabética).	Calendário dinâmico em DAX baseado no escopo das datas da base e com ordenação correta, mas sem marcar como tabela de data oficial ou sem relacionar adequadamente com ambas as datas da fato (publicação e homologação).	O modelo de dados contempla uma tabela de dimensão calendário construída via DAX, contendo atributos temporais completos e ordenação lógica configurada para suportar análises de inteligência temporal no relatório.
13	**Medidas DAX explícitas e boas práticas**	Não criou medidas explícitas (usou agregações implícitas arrastando colunas) ou criou menos de 5 medidas básicas.	Criou entre 6 e 14 medidas, com cálculo de percentuais por médias simples ou sem uso de boas práticas (sem tabela dedicada de	Implementou 15 ou mais medidas em tabela isolada, usando CALCULATE, DIVIDE e variáveis, mas com pequenas	A aplicação reúne uma tabela dedicada de medidas (no mínimo 15 indicadores) estruturadas

			medidas ou sem VAR/RETURN).	incoerências conceituais (ex.: esquecer de filtrar comparáveis na taxa de economia ou sem pasta por pergunta).	com sintaxe performática (VAR/RETURN) e funções analíticas (DAX avançado), organizadas de forma a responder diretamente às perguntas de negócio formuladas no projeto.
Nº	Critério de Avaliação	0,0	0,25	0,50	0,75
14	**Recursos avançados de usabilidade**	Relatório estático com navegação padrão entre abas inferiores, sem recursos avançados.	Tentou implementar menu ou tooltips, mas com falhas de funcionamento (bookmarks desconfigurados, botões que não redirecionam ou tooltips genéricos sem contexto).	Menu interativo e tooltips funcionais, mas com navegação truncada ou tooltips implementados em apenas um visual isolado sem agregar valor analítico.	O relatório apresenta uma interface interativa com menu retrátil funcional acionado por botões e indicadores (bookmarks), complementado por tooltips de página contextuais que detalham os indicadores sem poluir a visualização principal.
15	**Princípios de design (CRAP) e resposta às perguntas**	Layout desorganizado, excesso de cores aleatórias sem contraste, gráficos truncados e incapacidade de responder às perguntas de negócio.	Visuais distribuídos sem grid definido, problemas de alinhamento/proximidade e respostas parciais (3 ou menos perguntas respondidas com clareza).	Aplicação razoável de alinhamento e contraste, respondendo às 6 perguntas, mas com excesso de informação (poluição visual) ou sem a seção conclusiva (storytelling) em cada página.	O layout do painel segue um grid visualmente alinhado e consistente, com contraste de cores intencional voltado ao destaque de métricas-chave e escolha de

					visuais que favorecem a clareza analítica e a tomada de decisão.

7. ANEXO: DICIONÁRIO DOS DADOS BRUTOS (data/raw/)

São 3 arquivos CSV (separador „ UTF-8). Leia tudo como texto (dtype=str) e converta você mesmo. Origem: Portal Nacional de Contratações Públicas (PNCP), órgãos federais, contratações publicadas em 2025, uma amostra ao longo do ano (não são todas as contratações do país). A ligação entre os arquivos é numero_controle_pncp (e numero_item).
compras (1) ——< itens (N) ——< resultados (N)
numero_controle_pncp + numero_item

7.1. COMPRAS.CSV — UMA LINHA POR CONTRATAÇÃO (O "EDITAL")

Coluna	Significado
numero_controle_pncp	Identificador da contratação (chave)
ano_compra, sequencial_compra, numero_compra, processo	Numeração da contratação (ano_compra é o ano do número da compra e pode ser anterior a 2025; o que vale como data é data_publicacao)
objeto_compra	Descrição do que se está comprando
srp	True/False: Sistema de Registro de Preços (gera vários classificados por item)
cnpj_orgao, razao_social_orgao, nome_unidade	Órgão que comprou. cnpj_orgao também vem sujo (máscara, zero perdido) e o mesmo órgão tem vários CNPJ (unidades) e nomes escritos de jeitos diferentes
poder_id	E = Executivo, L = Legislativo, J = Judiciário, N = não informado
esfera_id	F = Federal (todos aqui)
uf_sigla, uf_nome, municipio, cod_ibge	Local da unidade compradora
modalidade_id, modalidade_nome	Modalidade: use o id como chave (tabela abaixo)
modo_disputa, situacao_compra	Detalhes do certame
valor_total_estimado, valor_total_homologado	Totais da contratação (não use para a fato: o grão é o item)
data_publicacao	Quando o edital foi publicado
data_abertura_proposta, data_encerramento_proposta	Janela de propostas

7.2. ITENS.CSV — UMA LINHA POR ITEM LICITADO

Coluna	Significado
numero_controle_pncp, numero_item	Chave do item
descricao	O que é o item
material_ou_servico, categoria_item	Classificação do item. material_ou_servico = Material ou Serviço; categoria_item vem toda como "Não se aplica" (não ajuda)
quantidade, unidade_medida	Quantidade licitada e unidade (a unidade tem grafias variadas e alguns valores estranhos, como UNIDADE 0,00; decida como agrupar)
valor_unitario_estimado, valor_total_estimado	O que o governo esperava pagar
sigiloso	True = orçamento sigiloso (sem estimado utilizável)
tem_resultado	True se o item tem fornecedor vencedor
situacao_item, criterio_julgamento	Situação e critério
catalogo_codigo_item	Código do catálogo oficial (quase sempre vazio)

7.3. RESULTADOS.CSV — UMA LINHA POR FORNECEDOR CLASSIFICADO EM CADA ITEM

Coluna	Significado
numero_controle_pncp, numero_item	Item ao qual o resultado pertence
sequencial_resultado, ordem_classificacao_srp	ordem_classificacao_srp = posição no ranking (1 = vencedor; vazio vale 1). sequencial_resultado = número de sequência do resultado (use para desempatar)
ni_fornecedor	CNPJ/CPF do fornecedor (atenção ao formato)
tipo_pessoa	PJ, PF ou PE (estrangeiro)
nome_fornecedor, porte	Nome e porte da empresa
quantidade_homologada	Quantidade efetivamente comprada
valor_unitario_homologado, valor_total_homologado	O que o governo pagou
data_resultado	Data da homologação

data_cancelamento	Preenchida = resultado cancelado

7.4. ANTES DE COMEÇAR, DESCUBRA (E ANOTE NO SEU README)

- Quantas linhas tem cada arquivo? Há numero_controle_pncp repetido em compras.csv?
- Que formatos de dinheiro, de data e de CNPJ aparecem? Quais colunas têm N/A, -, 0, vazio?
- Existe texto com acento quebrado (Ã§, Ã£)? Em quais colunas?
- Existe data_resultado anterior a data_publicacao?

7.5. TABELA DE MODALIDADES (MODALIDADE_ID → NOME)

id	Nome padronizado
4	Concorrência - Eletrônica
5	Concorrência - Presencial
6	Pregão - Eletrônico
7	Pregão - Presencial
8	Dispensa
9	Inexigibilidade
12	Credenciamento

7.6. TABELA UF → REGIÃO (PARA A PERGUNTA 5; O ARQUIVO NÃO TRAZ A REGIÃO)

Região	UFs
Norte	AC, AM, AP, PA, RO, RR, TO
Nordeste	AL, BA, CE, MA, PB, PE, PI, RN, SE
Centro-Oeste	DF, GO, MS, MT
Sudeste	ES, MG, RJ, SP
Sul	PR, RS, SC

8. ANEXO: NÚMEROS DE CONFERÊNCIA (PROVA REAL)

O professor rodou o pipeline completo com as regras da seção 4. Os números abaixo são o que deve aparecer na base limpa, na fato e no banco: use para saber se você está no caminho. Não copie os números: você precisa chegar a eles com o seu código e explicar como. Pequenas diferenças são normais quando a sua definição é diferente e justificada; diferenças grandes e sem explicação indicam erro (veja "Como interpretar diferenças", na seção 4.7).

Conferência	Valor esperado	Observação
Contratações (linhas de compras.csv)	2.042	contagem de linhas do arquivo
Itens (linhas de itens.csv)	7.077	contagem de linhas do arquivo
Itens sem resultado homologado (descartados pela regra 3)	852	inclusive os que só têm resultados cancelados; não contam como rejeitados (7.077 − 852 = 6.225 itens avaliados pela regra 4)
Resultados (linhas de resultados.csv)	15.896	contagem de linhas do arquivo
Itens na fato (1 linha por item de contratação)	6.126	grão do enunciado; 1 resultado vencedor por item
Itens rejeitados (inválidos)	99	quantidade ≤ 0, estimado/homologado inválidos, valores absurdos (só entre os 6.225 itens com resultado)
Contratações distintas na fato	1.962	
Fornecedores distintos	2.652	varia um pouco com o tratamento do documento ausente
Unidades compradoras (CNPJ de órgão distintos)	363	o mesmo órgão tem várias unidades; no ranking por órgão agrupe pelo nome
Soma do valor total homologado	R$ 8.044.498.805,74	deve bater com o banco (diferença de poucos centavos por arredondamento é normal)
Soma do valor total estimado, todos os itens	R$ 32.629.639.732,13	mostra por que misturar tudo distorce
Soma do estimado só da base comparável	R$ 6.867.663.469,91	veja a regra 6 (comparabilidade)
Itens na base comparável	5.457	

Economia nominal na base comparável	R$ 992.861.686,95	estimado − homologado, só nos itens comparáveis
Economia % na base comparável	14,46%	soma da economia ÷ soma do estimado comparável
Itens com sobrepreço (homologado > estimado)	27	
Itens com ciclo válido (dias entre publicação e homologação)	5.896	homologação anterior à publicação fica sem ciclo
Ciclo médio (dias)	48,1	
Ciclo máximo (dias)	611	
Itens sem ciclo	230	homologação anterior à publicação ou sem data; o item continua na fato
Perfil do gasto (% do volume homologado)	Obras e engenharia 60,8% · Serviços 36,6% · Bens 2,6%	com as 4 palavras de obra e o limite de palavra (\b); itens: 967 · 1.849 · 3.310